

GabeDA - Clasificación de Features por Workflow de Datos

Estructura del Workflow

INPUT → PREPROCESS → FILTERS → ATTRIBUTES → SCORE

INPUT: CSV transaccional (trans_id, fecha, producto, glosa, costo, total, cantidad, inith, initm, customer_id, customer_name, customer_location)

PREPROCESS: Limpieza, formato de fechas, eliminación de NAs, validación de tipos de datos

FILTERS: Cálculos fila por fila (nuevas columnas derivadas)

ATTRIBUTES: Agregaciones (por cliente, producto, fecha, etc.)

SCORE: Cálculo de scores/métricas finales usando attributes

SECCIÓN A: Analítica Tradicional (Capacidades Actuales)

A1. Análisis Pareto (Regla 80/20)

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ ATTRIBUTES:
 - Agregación de ventas por producto: `SUM(total) GROUP BY producto`
 - Agregación de ventas por cliente: `SUM(total) GROUP BY customer_id`
 - Ordenamiento descendente por total
- ☒ SCORE:
 - Cálculo de % acumulado
 - Identificación del punto 80/20
 - Ranking de contribución

Outputs clave:

- Lista de productos Top 20% que generan 80% ingresos
 - Lista de clientes Top 20% que generan 80% ingresos
-

A2. Alertas de Inventario

Workflow:

- ☒ PREPROCESS: Limpieza de datos, validación de stock
- ☒ FILTERS:
 - Cálculo de días desde última venta: `fecha - MAX(fecha)` per producto

- ☒ ATTRIBUTES:
 - Stock actual por producto (si se tiene campo stock, o inferido de inith/initm)
 - Promedio ventas diarias por producto: $\text{AVG}(\text{cantidad})$ per día per producto
 - Días sin movimiento: $\text{current_date} - \text{MAX}(\text{fecha})$ per producto
- ☒ SCORE:
 - Días de stock restante = $\text{stock_actual} / \text{promedio_ventas_diarias}$
 - Flags de alerta: stock_bajo (< 7 días), sin_movimiento (> 90 días)

Outputs clave:

- Productos con < 7 días de stock
 - Productos sin venta en 90+ días
-

A3. Salud de Inventario

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ FILTERS:
 - Margen por transacción: $\text{total} - \text{costo}$
 - Valor inventario por producto: $\text{stock_actual} * \text{costo_unitario}$
- ☒ ATTRIBUTES:
 - Rotación de inventario = $\text{total_ventas_periodo} / \text{promedio_inventario}$
 - Días de inventario = $365 / \text{rotación}$
 - Valor total inventario estancado (> 60 días sin venta)
 - % inventario lento vs total
- ☒ SCORE:
 - Índice de salud (0-100) basado en rotación y días
 - Categorización: saludable / atención / crítico

Outputs clave:

- Monto en inventario estancado
 - Rotación por producto
 - Score de salud de inventario
-

A4. Segmentación de Clientes

Workflow:

- ☒ PREPROCESS: Limpieza de datos, estandarización customer_id
- ☒ ATTRIBUTES:
 - Recency: días desde última compra por cliente
 - Frequency: número de transacciones por cliente
 - Monetary: total gastado por cliente
 - Primera compra: $\text{MIN}(\text{fecha})$ per customer_id
- ☒ SCORE:
 - Segmentos RFM:

- Frecuentes: frequency > X, recency < Y
- Ocasionales: frequency mediano, recency mediana
- Dormidos: recency > 90 días, frequency > 0 histórico
- Nuevos: primera compra < 60 días

Outputs clave:

- Conteo de clientes por segmento
 - Lista de clientes por categoría
-

A5. Velocidad de Productos

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ FILTERS:
 - Extracción de día juliano: DATE_TO_DAY(fecha)
- ☒ ATTRIBUTES:
 - Días entre transacciones por producto
 - Promedio días entre ventas: AVG(días_entre_ventas) per producto
 - Frecuencia de venta: COUNT(trans_id) / días_operación per producto
- ☒ SCORE:
 - Velocidad categorizada:
 - Rápida: < 7 días entre ventas
 - Media: 7-30 días
 - Lenta: > 30 días

Outputs clave:

- Días promedio para vender cada producto
 - Categorización velocidad
-

A6. Pronóstico de Ventas Básico

Workflow:

- ☒ PREPROCESS: Limpieza, ordenamiento temporal
- ☒ FILTERS:
 - Extracción de mes, año: MONTH(fecha), YEAR(fecha)
- ☒ ATTRIBUTES:
 - Ventas mensuales históricas: SUM(total) GROUP BY año, mes
 - Promedio móvil (3 meses, 6 meses)
 - Tendencia lineal
- ☒ SCORE:
 - Proyección mes siguiente usando:
 - Promedio móvil
 - Tendencia lineal
 - Estacionalidad (si detectada)

Outputs clave:

- Ventas proyectadas próximo mes
 - Intervalo de confianza
-

A7. Análisis de Tendencias Temporales

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ FILTERS:
 - Extracción temporal: año, mes, semana
- ☒ ATTRIBUTES:
 - Ventas por período (mes, año)
 - Comparaciones período anterior
 - Comparaciones mismo período año anterior
- ☒ SCORE:
 - % cambio mes vs mes anterior: $(\text{mes_actual} - \text{mes_anterior}) / \text{mes_anterior}$
 - % cambio año sobre año: $(\text{mes_actual_año} - \text{mes_mismo_año_anterior}) / \text{mes_mismo_año_anterior}$
 - Dirección de tendencia: creciente/estable/decreciente

Outputs clave:

- % crecimiento mes vs mes
 - % crecimiento año sobre año
 - Gráfica de tendencia
-

SECCIÓN B: Nuevas Capacidades Analíticas (Sin IA)

B1. Análisis de Rentabilidad por Producto

Workflow:

- ☒ PREPROCESS: Limpieza, validación costo y total
- ☒ FILTERS:
 - Margen unitario: $\text{total} - \text{costo}$
 - % margen: $(\text{total} - \text{costo}) / \text{total} * 100$
- ☒ ATTRIBUTES:
 - Margen total por producto: $\text{SUM}(\text{margen})$ GROUP BY producto
 - % margen promedio por producto: $\text{AVG}(\% \text{ margen})$ per producto
 - Volumen de ventas por producto
- ☒ SCORE:
 - Rentabilidad = $\text{margen_total} * \text{volumen_ventas}$
 - Ranking por rentabilidad
 - Categorización: alta/media/baja rentabilidad

Outputs clave:

- Productos con mayor margen absoluto
 - Productos con mayor % margen
 - Matriz volumen vs margen
-

B2. Análisis de Estacionalidad

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ FILTERS:
 - Componentes temporales: mes, trimestre, día_semana
 - Flags: es_fin_semana, es_feriado
- ☒ ATTRIBUTES:
 - Ventas por mes (agregadas multi-año)
 - Ventas por día de semana
 - Ventas por trimestre
 - Índice estacional = $\text{ventas_período} / \text{promedio_general}$
- ☒ SCORE:
 - Coeficiente de variación estacional
 - Períodos peak vs valle
 - Factores de estacionalidad por período

Outputs clave:

- Meses con mayor/menor venta
 - Días de semana más activos
 - Factores de ajuste estacional
-

B3. Análisis de Canastas (Market Basket)

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ FILTERS:
 - Agrupación de transacciones: GROUP BY trans_id, customer_id, fecha
 - Creación de "cestas" (productos comprados juntos en misma transacción/día)
- ☒ ATTRIBUTES:
 - Frecuencia de pares de productos: COUNT(producto_A AND producto_B en misma transacción)
 - Frecuencia individual de cada producto
- ☒ SCORE:
 - Support: $\text{freq}(A,B) / \text{total_transacciones}$
 - Confidence: $\text{freq}(A,B) / \text{freq}(A)$
 - Lift: $\text{confidence}(A \rightarrow B) / \text{support}(B)$
 - Reglas de asociación con lift > 1

Outputs clave:

- Pares de productos frecuentemente comprados juntos
 - Reglas: "Si compra A, probablemente compre B"
 - Lift scores
-

B4. Detección de Clientes en Riesgo de Abandonar

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ ATTRIBUTES:
 - Recencia actual por cliente: `days_since_last_purchase`
 - Frecuencia histórica esperada: `AVG(días_entre_compras)` per customer
 - Desviación de patrón: `recencia_actual - frecuencia_esperada`
 - Valor histórico del cliente: `SUM(total)` per customer
- ☒ SCORE:
 - Riesgo de churn = `recencia_actual / frecuencia_esperada`
 - Categorías:
 - Alto riesgo: `recencia > 2x frecuencia esperada`
 - Riesgo medio: `recencia > 1.5x frecuencia`
 - Activo: dentro del patrón normal
 - Prioridad = `riesgo * valor_histórico`

Outputs clave:

- Lista de clientes en riesgo alto
 - Clientes priorizados por valor
 - Días desde esperada compra
-

B5. Análisis de Punto de Reorden Inteligente

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ ATTRIBUTES:
 - Velocidad de venta diaria: `AVG(cantidad)` per día per producto
 - Desviación estándar de ventas: `STDDEV(cantidad)` per producto
 - Lead time proveedor (si disponible o asumido)
 - Stock actual
 - Stock de seguridad = `Z_score * STDDEV(ventas_diarias) * SQRT(lead_time)`
- ☒ SCORE:
 - Punto de reorden = `(velocidad_venta * lead_time) + stock_seguridad`
 - Cantidad óptima de pedido (EOQ) si se tienen costos
 - Días hasta stockout: `stock_actual / velocidad_venta`

Outputs clave:

- Punto de reorden por producto
- Cuándo pedir (alerta cuando `stock < punto_reorden`)

- Cantidad sugerida de pedido
-

B6. Dashboard de Indicadores Clave (KPIs)

Nota: No es un proceso de datos per se, sino una visualización de outputs de otros análisis.

Inputs desde otros workflows:

- Ventas del mes (A7)
- Margen promedio (B1)
- Inventario crítico (A2)
- Clientes activos (A4)
- Productos top (A1)
- Tendencia de crecimiento (A7)

Presentación:

- Formato de dashboard visual
 - Métricas en tiempo real
 - Comparaciones período anterior
 - Indicadores visuales (colores, gráficos)
-

B7. Comparación con Meses/Años Anteriores (Benchmarking Personal)

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ FILTERS:
 - Componentes de fecha: año, mes, semana
- ☒ ATTRIBUTES:
 - KPIs por período:
 - Ventas totales
 - Margen promedio
 - Cantidad de transacciones
 - Ticket promedio: $\text{AVG}(\text{total})$ per transacción
 - Productos vendidos
 - Clientes únicos
- ☒ SCORE:
 - Variaciones período sobre período:
 - $(\text{KPI}_{\text{actual}} - \text{KPI}_{\text{anterior}}) / \text{KPI}_{\text{anterior}}$
 - Variaciones año sobre año:
 - $(\text{KPI}_{\text{mes_actual}} - \text{KPI}_{\text{mismo_mes_año_anterior}}) / \text{KPI}_{\text{mismo_mes_año_anterior}}$
 - Índices de desempeño relativo

Outputs clave:

- Tabla comparativa multi-período
- % cambios en cada métrica

- Indicadores de mejora/deterioro

SECCIÓN C: Capacidades con Inteligencia Artificial

C1. Asistente de Voz/Chat para Consultas

Workflow:

- **No es parte del pipeline de datos, sino una capa de interfaz**
- Consume outputs de ATTRIBUTES y SCORES de otros análisis

Arquitectura:

- INPUT: Query en lenguaje natural (español)
- NLP Processing: Interpretación de intención del usuario
- Query Translation: Convierte pregunta a consulta de datos
- Data Retrieval: Obtiene datos de attributes/scores existentes
- Response Generation: Genera respuesta en lenguaje natural

Requisitos de datos:

- Acceso a todos los attributes y scores generados
- Metadata de qué análisis están disponibles
- Contexto del negocio del cliente

Ejemplo:

- Usuario: "¿Cuáles fueron mis 5 productos más vendidos en julio?"
- Sistema:
 - Identifica: query de ranking de productos
 - Filtra: mes = julio
 - Obtiene: output de A1 (Pareto) filtrado
 - Responde: "Los más vendidos en julio fueron..."

C2. Explicaciones Inteligentes ("¿Por Qué Pasó Esto?")


Workflow:


- Capa de análisis **post-SCORE** que genera narrativa

Arquitectura:

Detecta cambio → Identifica causas posibles → Genera explicación

Proceso:

1. Detecta anomalía/cambio (ej: ventas -15%)
2. Analiza factores contribuyentes:
 -  ATTRIBUTES correlacionados:






- Quiebres de stock (de A2)
 - Días operacionales (calendarios, feriados)
 - Cambios en mix de productos
- Factores externos (si disponible):
 - Competencia
 - Estacionalidad (de B2)
- 3.  SCORE: Peso de cada factor
- 4. AI: Genera narrativa explicativa con recomendaciones

Inputs requeridos:

- Todos los attributes de análisis previos
 - Calendario de eventos (feriados, campañas)
 - Datos de contexto (competencia, clima, etc.) si disponible
-

C3. Alertas Predictivas

Workflow:

-  PREPROCESS: Limpieza de datos
-  FILTERS: Cálculos temporales
-  ATTRIBUTES:
 - Series temporales por producto/cliente
 - Tendencias recientes (últimas 2-4 semanas)
 - Desviaciones de patrón normal
-  SCORE:
 - Modelos predictivos simples:
 - Proyección lineal
 - Promedio móvil exponencial
 - Detección de tendencias
 - Umbrales de alerta configurables
-  AI:
 - Algoritmos de forecasting (ARIMA, Prophet)
 - Clasificación de urgencia de alerta
 - Generación de mensaje contextual

Tipos de alertas:

1. Alerta de Stockout:

- Predicción: días hasta stock = 0
- Trigger: < 7 días predichos

2. Alerta de Demanda:

- Detección: tendencia acelerada > 30%
- Trigger: Z-score > 2

3. Alerta de Churn:

- Score de riesgo de B4
- Trigger: cliente de alto valor en riesgo alto

C4. Recomendaciones Automáticas de Acciones



Workflow:

- **Post-SCORE:** Motor de recomendaciones basado en reglas + AI

Arquitectura:

Situación detectada → Reglas de negocio → Opciones generadas → Ranking → Recomendación

Proceso:

1. Identifica problema (ej: inventario lento)
2.  Recupera ATTRIBUTES relevantes:
 - Valor en inventario lento (de A3)
 - Productos afectados
 - Margen histórico (de B1)
 - Productos complementarios (de B3)
3. Aplica reglas de negocio:
 - Si margen > 40% → puede descontar 30%
 - Si tiene complemento popular → bundle
4.  AI:
 - Genera múltiples estrategias
 - Evalúa impacto esperado
 - Rankea por probabilidad de éxito
5. Output: Lista priorizada de acciones

Ejemplo lógica:

```
if producto.dias_sin_venta > 90:
    opciones = []
    if producto.margen > 40%:
        opciones.append("Descuento 30%")
    if tiene_complemento_popular(producto):
        opciones.append(f"Bundle con {complemento}")
    if producto.costo < valor_promedio_inventario * 0.1:
        opciones.append("Liquidación")
    return AI_rank_opciones(opciones, contexto_negocio)
```

C5. Procesamiento Inteligente de Documentos (OCR + AI)


Workflow:

- **Enhancement del INPUT stage**

Arquitectura:

Foto/Scan → OCR → Extracción de campos → Validación → Estructuración → INPUT

Proceso:

1. **INPUT:** Imagen de boleta/factura
2. **OCR Processing:**
 - Detección de texto
 - Reconocimiento de caracteres
3.  **AI - Field Extraction:**
 - Identifica tipo de documento (boleta, factura, inventario)
 - Extrae campos:
 - Fecha
 - Monto total
 - Items/productos
 - Proveedor/cliente
 - RUT si aplica
4. **Validation:**
 - Formato de fecha
 - Validación de RUT
 - Coherencia de montos
5. **Estructuración:**
 - Convierte a formato CSV estándar
 - Mapea a schema: (trans_id, fecha, producto, glosa, costo, total, cantidad, customer_id, etc.)
6. **OUTPUT:** Row(s) para añadir al INPUT CSV

Tecnologías requeridas:

- OCR engine (Tesseract, Google Vision API, AWS Textract)
- AI model para clasificación de documentos
- NER (Named Entity Recognition) para extracción de campos
- Reglas de validación Chile-específicas (formato RUT, formato boleta)

C6. Coach de Negocios Personalizado con IA

Workflow:

- **Capa conversacional que consume todos los ATTRIBUTES y SCORES**

Arquitectura:

Pregunta → Entendimiento de intención → Análisis multi-source → Síntesis → Recome

Componentes:

1. Conversational AI:

- Procesa pregunta del usuario
- Mantiene contexto de conversación

2. Knowledge Retrieval:

- Accede a TODOS los attributes generados
- Identifica qué análisis son relevantes

3. Business Logic:

- Reglas de negocio del rubro
- Best practices de retail/comercio

4. 🤖 AI Reasoning:

- Analiza múltiples attributes simultáneamente
- Identifica patrones y oportunidades
- Prioriza recomendaciones

5. Response Generation:

- Genera explicación comprensible
- Incluye datos específicos del negocio
- Sugiere acciones concretas

Ejemplo flujo:

Usuario: "¿Cómo puedo aumentar mis ventas?"



Coach AI:

1. Analiza ventas actuales (A7)
2. Identifica clientes dormidos (B4) → 8 clientes, \$500k/mes histórico
3. Detecta quiebres de stock (A2) → Producto A con alta demanda
4. Analiza días de venta (B2) → Viernes +40% vs otros días
5. Sintetiza: 3 oportunidades priorizadas
6. Genera respuesta personalizada con números del negocio

C7. Detección de Anomalías Automática

Workflow:

- ☒ PREPROCESS: Limpieza de datos
- ☒ FILTERS: Cálculos temporales, ventanas móviles
- ☒ ATTRIBUTES:
 - Series temporales de métricas clave:
 - Ventas diarias por producto

- Gastos operacionales
 - Ticket promedio
 - Tráfico de clientes
- Estadísticas de normalidad:
 - Media móvil (7 días, 30 días)
 - Desviación estándar
 - Percentiles (P5, P95)
-  SCORE:
 - Z-score para cada métrica: $(\text{valor_actual} - \text{media}) / \text{std_dev}$
 - Detección de outliers: $|\text{Z-score}| > 2$
 - Tipo de anomalía: spike positivo/negativo, cambio de tendencia
-  AI:
 - Algoritmos de detección:
 - Isolation Forest
 - Autoencoders para patrones complejos
 - LSTM para series temporales
 - Clasificación de severidad
 - Contextualización (es anomalía real o evento esperado)

Tipos de anomalías detectables:




1. **Anomalía de volumen:** Producto vende 0 vs 5-8 diario normal
2. **Anomalía de gasto:** Gastos +40% sin razón aparente
3. **Anomalía de patrón:** Cambio de día peak de viernes a sábado
4. **Anomalía de distribución:** Mix de productos muy diferente


Output:

- Alerta con:
 - Qué métrica
 - Valor esperado vs observado
 - Severidad (crítico/moderado/información)
 - Sugerencia de investigación

C8. Pronósticos Inteligentes Multi-Factor

Workflow:

-  PREPROCESS: Limpieza, imputación de valores faltantes
-  FILTERS:
 - Features temporales: mes, día_semana, semana_año, es_feriado
 - Features de lag: ventas_7d_atras, ventas_30d_atras
 - Features de tendencia: crecimiento_reciente
-  ATTRIBUTES:
 - Agregaciones temporales multinivel
 - Factores estacionales (de B2)
 - Eventos calendarios (feriados, campañas)
 - Variables exógenas si disponible (clima, competencia)

-  SCORE - ML Models:
 - **Modelo 1 - Simple:** Promedio móvil ponderado + estacionalidad
 - **Modelo 2 - Estadístico:** ARIMA o Prophet
 - **Modelo 3 - ML:**
 - XGBoost o LightGBM con features multi-factor
 - Features: lag values, día semana, mes, tendencia, estacionalidad, eventos
 - **Ensemble:** Combina predicciones de múltiples modelos

Feature Engineering para ML:

```
features = {
    'temporal': ['mes', 'dia_semana', 'semana_año', 'trimestre'],
    'lags': ['ventas_lag_7', 'ventas_lag_14', 'ventas_lag_30'],
    'rolling': ['ventas_rolling_7d', 'ventas_rolling_30d'],
    'trends': ['tendencia_7d', 'tendencia_30d'],
    'seasonality': ['factor_estacional_mes', 'factor_dia_semana'],
    'events': ['es_feriado', 'dias_hasta_feriado', 'es_mes_campaña'],
    'external': ['competencia_nueva', 'clima_categoria'] # si disponible
}
```

Output avanzado:

- Pronóstico puntual (valor esperado)
- Intervalos de confianza (P10, P90)
- Descomposición: tendencia + estacionalidad + residual
- Factores de influencia (feature importance)
- Recomendaciones operativas basadas en forecast

Ejemplo output:

```
Pronóstico Noviembre 2025:
- Ventas esperadas: $4.2M (rango: $3.9M - $4.5M)
- Basado en:
  * Histórico nov 2023-2024: +$50k cada año
  * Tendencia actual: +12% últimos 3 meses
  * Black Friday semana 4: +30% impacto esperado
  * Factor estacional noviembre: 1.15x
- Drivers principales:
  1. Estacionalidad (40% de predicción)
  2. Tendencia de crecimiento (30%)
  3. Evento Black Friday (20%)
  4. Día de semana (10%)
- Recomendaciones:
  * Productos A,B,C: aumentar stock 40%
  * Producto D: mantener normal
  * Staff: considerar +2 personas semana 4
- Riesgos:
```

- * Competencia nueva (monitorear primeras 2 semanas)
- * Incertidumbre: $\pm \$300k$ (7%)

RESUMEN: Arquitectura de Datos Completa

Pipeline Core (Todos los Features)

```
CSV Input
  ↓
[PREPROCESS] → Datos limpios y validados
  ↓
[FILTERS] → Datos + columnas derivadas (margins, dates, etc.)
  ↓
[ATTRIBUTES] → Agregaciones por entidad (cliente, producto, período)
  ↓
[SCORES] → Métricas finales, rankings, clasificaciones
  ↓
[OUTPUTS] → Reportes, dashboards, alertas
```

Capas AI (Enhancements)

Input Enhancement:

- C5: OCR/Document Processing → mejora INPUT

Analysis Enhancement:

- C3: Predictive Alerts → mejora SCORE con ML forecasting
- C7: Anomaly Detection → mejora SCORE con ML detection
- C8: Multi-factor Forecasting → mejora SCORE con ML avanzado

Interpretation Enhancement:

- C2: Intelligent Explanations → post-SCORE narrativa
- C4: Automated Recommendations → post-SCORE acción

Interface Enhancement:

- C1: Conversational Interface → consume ATTRIBUTES/SCORES
- C6: Business Coach → consume todo, razonamiento avanzado

Priorización de Implementación

Fase 1: Foundation (Sin AI)

Implementar: A1-A7, B1, B7

- Pipeline básico: Input → Preprocess → Filters → Attributes → Score

- Analytics fundamentales

Fase 2: Advanced Analytics (Sin AI)

Implementar: B2-B6

- Requires más feature engineering
- Análisis más sofisticados

Fase 3: AI Layer - Quick Wins

Implementar: C2 (Explanations), C5 (OCR)

- C2 usa LLM sobre datos existentes (rápido)
- C5 resuelve pain point crítico de input

Fase 4: AI Layer - Predictive

Implementar: C3 (Alerts), C7 (Anomalies)

- Modelos ML simples primero
- Mejora operativa significativa

Fase 5: AI Layer - Advanced

Implementar: C8 (Advanced Forecasting), C4 (Recommendations)

- ML más complejo
- Requiere datos históricos suficientes (6+ meses)

Fase 6: AI Interface

Implementar: C1 (Chat), C6 (Coach)






- Capa conversacional sobre todo lo anterior
- Mayor impacto UX

Dependencias de Datos

Campos CSV actuales:

- ☒ trans_id, fecha, producto, glosa, costo, total, cantidad
- ☒ customer_id, customer_name, customer_location
- ☒ inith, initm (horarios?)

Campos adicionales útiles:

-  **stock_actual:** para A2, A3, B5 (crítico)
-  **categoria_producto:** mejora B3, análisis categorial
-  **proveedor:** para análisis de proveedores
-  **costo_fijo_producto:** para B1 mejorado
-  **lead_time_proveedor:** para B5 más preciso

- 🟡 **es_feriado, eventos:** para C8 forecasting

Fuentes externas opcionales:

- 📅 Calendario de feriados Chile
 - 🌤️ Datos de clima (si aplica al negocio)
 - 💰 Indicadores económicos (IPC, tipo cambio)
 - 🏢 Datos de competencia (si disponible)
-

Este documento debe actualizarse a medida que:

1. Se implementen nuevos features
2. Se descubran nuevas dependencies
3. Se refine el data pipeline
4. Se agreguen nuevos campos al CSV